


SOLO 减少单 token 决策前的等待

ContractNLI 全部 1,088 条决策 · JEV-9B BF16 · RTX 4090 · 并发 4 · 开启前缀缓存



Prefill/首 token 区间中位数: 726.1 → 219.3 ms (3.31×)

首 token 后 Decode: 全部 2,176 次测量均为 0.0 ms · 每次请求只输出 1 token